第 43 卷 第 x 期
2026 年 x 月

计 算 物 理
CHINESE JOURNAL OF COMPUTATIONAL PHYSICS

Vol. 43, No. x
xxx., 2026

文章编号：1001-246X(2026)00-0001-13

基于改进 MADDPG 算法的水平井智能滑套完井开度优化研究

李斌旺[1]， 汪志明[1,*]

（1. 中国石油大学(北京), 石油工程学院, 北京 102249）

摘 要：水平井智能滑套完井系统的开度优化涉及多变量、强耦合、非线性等复杂问题。本研究建立了水平井滑套-储层耦合流动产能模型,其理论预测值与数值模拟结果对比验证后的误差在12%以内。在此模型的基础上,本文以马尔可夫决策理论为强化学习框架,通过引入了优先经验回放机制,提出了一种用于水平井多井段智能滑套完井系统优化的PER-MADDPG(Prioritized Experience Replay- Multi-Agent Deep Deterministic Policy Gradient)算法。结果表明,与DDPG和MADDPG相比,采用了PER-MADDPG优化的水平井滑套完井在训练过程中以最小的损失实现了最高的奖励,累计产油增加了10.7%,2年后的综合含水率下降6.4%。该算法通过智能的筛选和回放显著提升了智能体的学习效率与样本利用率,为油井生产过程中的多智能体实时调控提供理论指导。

关键词：滑套完井；油藏数值模拟；深度强化学习；多智能体深度确定性策略梯度

中图分类号：TE323 **文献标识码**：A DOI: 10.19596/j.cnki.1001-246x.9221

0 引言

水平井技术作为高效开发非常规油气资源的关键手段,其完井效果直接影响油田的最终采收率[1–]。智能滑套控制阀完井技术能够智能调节各产层开度,并可根据实际情况局部关井,从而抑制高含水层的突破并均衡产液剖面。这一技术是实现均衡开采和控水增油的重要途径。水平井滑套-储层耦合流动模型如图1所示,储层渗流与近井地带复杂流动模型的准确表征与油藏流入动态的快速预测有助于指导滑套开启度的方案调整[5–]。然而,水平井储层非均质性强、各产层间的渗流干扰复杂,如何科学、动态地优化多井段的滑套开度实时调控方案,是一个涉及多变量、强耦合、非线性的复杂优化问题。传统基于静态地质模型及优化方法,难以应对复杂动态变化的油藏环境,从而制约了水平井滑套完井技术对油藏增产潜力的充分发挥[9]。

深度强化学习(Deep Reinforcement Learning, DRL)因其能够在高维状态空间中实现策略搜索、自主特征提取以及处理强非线性时序决策问题而备受关注,成为油藏动态优化的重要数值工具[10–15]。如通过深度强化学习来研究水驱、气水驱及多参数注采优化问题[16–18]。其应用效果表明,DRL能够在考虑复杂约束的前提下,显著提升原油采收率或净现值。Zhang等[19]则针对实际复杂油田,采用AC(Actor-Critic)框架进行注水优化,成功实现了原油驱替效率和项目净现值(Net Present Value, NPV)的最大化。Yan等[20]采用基于PPO-CNN(Proximal Policy Optimization- Convolutional Neural Network)的实时压裂–注采控制策略,将高维地层参数映射为低维策略表征,实现了复杂应力场下压裂参数的动态优化。Miftakhov等[21]创新性地以油藏数值模拟模型的参数作为状态输入,利用DRL代理直接优化注采策略,为处理复杂油藏动态提供了新思路。Nasir等[22]的工作证明了DRL在油藏管理中的实用性,其效果已非常接近通过数值计算得到的确定性优化方案的结果。此外,Guevara等[23]将DRL应用于蒸汽辅助重力泄油过程的优化,进一步拓展了其应用场景。但DRL仍面临样本利用率低、多智能体场景中策略不稳定等收敛退化等问题,这对于需要分布式协同决策的水平井多滑套调控场景而言,存在固有局限性。Ma等[24]通过对比深度Q网络(Deep Q-Network, DQN)、双DQN(Double Deep Q-Network, DDQN)、决斗DQN(Dueling Double Deep Q-Network, D3QN)和深度确定性策略梯度(Deep

收稿日期：2025-12-02； **修回日期**：2026-01-08

第一作者：李斌旺，博士研究生，研究方向为控水防砂完井与优化，E-mail：2021310154@student.cup.edu.cn

*通信作者：汪志明， E-mail：wangzm@cup.edu.cn

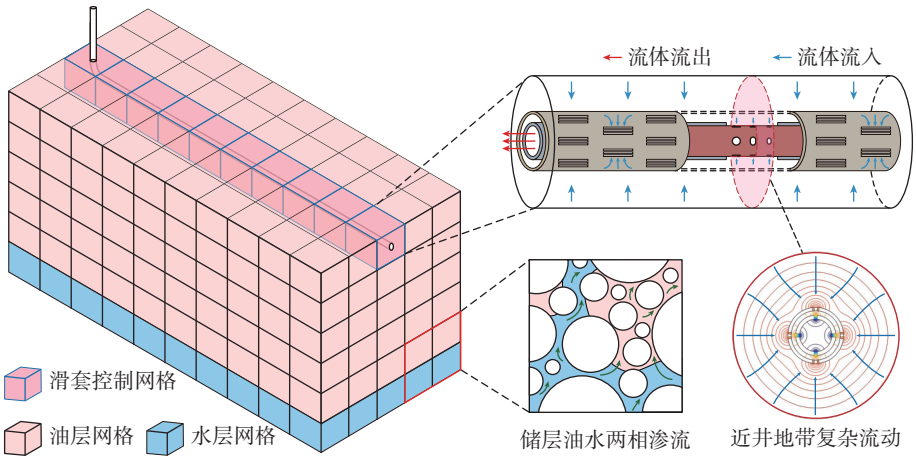


图 1 水平井滑套–储层耦合流动示意图

Fig. 1 Schematic of the Sliding Sleeve-Reservoir Coupled Flow Model in a Horizontal Well.

Deterministic Policy Gradient, DDPG)算法，来优化地质条件不确定性下水驱的净现值，发现DDPG收敛速度最快，更适合解决连续调控的复杂油藏生产问题。在此基础上，Li等[25]提出了应用多智能体深度确定性策略梯度(Multi-Agent Deep Deterministic Policy Gradient , MADDPG)来优化CO_2在多井组条件下的注入速率。Abdalla等[26]应用了MADDPG来优化多井组在连续注采动作件下的水驱过程，使得净现值得到明显提升。基于以上研究，MADDPG算法因能够处理连续动作空间并建模多井段间的状态交互关系，更适用于智能滑套完井的开度策略优化。

然而，MADDPG 在复杂驱替环境中普遍存在经验利用率低、对非平稳状态敏感、策略梯度易震荡等不足，限制了其在实际油藏控制中的应用性能[27]。针对上述问题，本文构建了基于马尔可夫决策理论的强化学习框架，用于水平井多井段智能滑套完井的开度优化。在此基础上，通过引入优先经验回放(Prioritized Experience Replay)机制，提出了PER-MADDPG算法。在建立了滑套–储层耦合流动产能模型并验证其可靠性后，基于时间差分误差(Temporal Difference Error, TD-error)为经验样本分配优先级，提高智能体对渗流动态与含水率等关键状态的学习效率，从而为实现水平井滑套完井的实时优化调控提供一种新的解决途径。

1 水平井滑套–储层耦合流动模型

典型的智能滑套管柱完井的油藏网络模型及其近井地带流动如图1所示，从储层远端以径向流方式逐渐汇聚流向智能滑套管柱的外部防砂筛管部分和内部带滑套的油管[28]。为此，将水平井智能滑套完井的产能模型划分为储层的渗流模型和滑套近井地带的复杂流动模型，用于准确表征油藏流入动态，指导滑套开启度的方案调整。

1.1 油藏流动模型

目前用于描述油藏流动行为的数学模型主要依赖于油藏数值模拟方法。该方法基于质量守恒定律和达西定律，推导出表征油藏中流体流动的数学模型，并通过求解相应的偏微分方程，将其转化为便于计算的线性方程组[29–]。选择油水两相流动为研究目标，建立底水油藏两相流动数学模型：

$$-\nabla\cdot\left(\frac{\rho_o}{B_o}\boldsymbol{u}_o\right)+q_o=\frac{\partial}{\partial t}\left(\frac{\phi\rho_o}{B_o}S_o\right)\quad,\tag{1}$$

$$-\nabla\cdot\left(\frac{\rho_w}{B_w}\boldsymbol{u}_w\right)+q_w=\frac{\partial}{\partial t}\left(\frac{\phi\rho_w}{B_w}S_w\right)\quad,\tag{2}$$

式中ρ_o、ρ_w分别是油相密度和水相密度，单位为$\mathrm{kg/m^3}$；$\boldsymbol{u}_o$、$\boldsymbol{u}_w$分别是油相流速和水相流速，单位为m/s；B_o、B_w分别是油相体积系数和水相体积系数；q_o、q_w分别是油相质量流量和水相质量流量，单位为kg/s；ϕ是孔隙度；S_o、S_w分别是油相饱和度和水相饱和度。

每一相的达西定律可以写为：

$$\boldsymbol{u}_o = -\frac{k_{ro}}{\mu_o} k \left(\nabla p_o - \rho_o \boldsymbol{g} \nabla z\right) \quad , \tag{3}$$

$$\boldsymbol{u}_w = -\frac{k_{rw}}{\mu_w} k \left(\nabla p_w - \rho_w \boldsymbol{g} \nabla z\right) \quad , \tag{4}$$

式中μ_o、μ_w分别是油相黏度和水相黏度, 单位为mPa·s; k是储层绝对渗透率, 单位为μm^2; k_{ro}、k_{rw}分别是油相相对渗透率和水相相对渗透率; $\boldsymbol{g}$是重力, 单位为m/s^2; p_o、p_w分别是油相压力和水相压力, 单位为MPa。

考虑完井表皮效应后[32], 可将上述质量守恒方程整理为:

$$q_o = \frac{2\pi k k_{ro} \left(p_o - p_{wf}\right)}{B_o \mu_o \left(\ln \dfrac{r_e}{r_w} + S_f\right)} \quad , \tag{5}$$

$$q_w = \frac{2\pi k k_{rw} \left(p_w - p_{wf}\right)}{B_w \mu_w \left(\ln \dfrac{r_e}{r_w} + S_f\right)} \quad , \tag{6}$$

式中P_{wf}是井底流压, 单位为MPa; r_e、r_w分别是油藏供给半径和井筒半径, 单位为m; S_f是表皮系数, 无因次。

1.2　滑套完井管柱表皮模型

1.2.1　滑套完井管柱数值模拟

如图2所示, 本文通过Comsol商业数值模拟软件构建水平井滑套–储层耦合流动物理模型, 将流动区域划分为储层渗流区域和井筒管流部分, 采用Navier-Stokes方程描述割缝筛管、滑套和井筒组成自由流动区域。储层流动区域通过给定的渗透率和孔隙度等参数, 采用Darcy渗流方程刻画。模型设置有2个入口和一个出口, 分别是井筒的速度入口, 圆形储层边界的压力入口和井筒另一端的速度出口。储层边界平行于井筒出口和入口的2个端面设置为对称边界。储层与井壁交界区域设置为内部, 其他界面均设置为壁面。

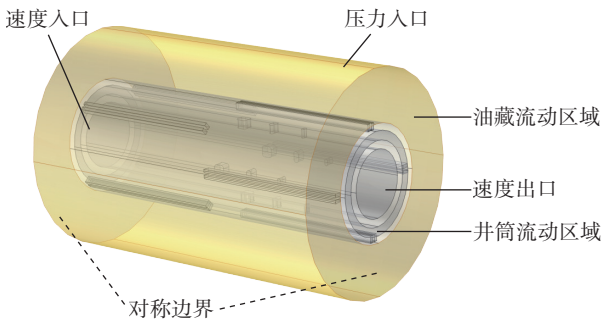


图 2　滑套完井管柱近井地带流动物理模型

Fig. 2　Physical model of sliding sleeve completion near the wellbore.

综合考虑周向孔数、滑套开度、渗透率、黏度、储层压力和储层供给半径对近井地带复杂流动特征的影响, 通过商业数值模拟软件设计正交化数值模拟方案, 每个因素6水平, 一共开展了36组数值计算。参数取值如表1所示, 通过研究各个因素在不同的参数设置组合下, 对储层压力剖面的影响, 分析滑套完井管柱在近井地带引起的复杂流动机理。

表 1　滑套完井数值模拟参数

Table 1　Numerical Simulation Parameters of Sliding Sleeve Completion

参数	周向孔数 m_s	滑套开度 λ	渗透率 $K/10^{-3}$μm^2	油黏度 μ_o/ mPa·s	储层压力 P_0/MPa	供给半径 r_e/m
取值	2、3、4、6、8、10	0、0.1、0.4、0.6、0.9、1	100、200、500、1 000、2000、3 000	0、40、60、80、100、120	1、12、13、14、15、16	0.5、1、2、3、5、8

表皮系数是根据流体通过滑套完井管柱与裸眼井的压力降差异确定的[32–33]。为此, 以定井底流压的生产方式, 模拟不同滑套管柱参数下的出口流量。由于裸眼完井不存在附加压降引起的表皮, 所以S_f= 0, 在生产压差相同的情况下, 通过公式(5)可以得到数值计算的表皮系数公式:

$$\frac{Q_{\text{滑套}}}{Q_{\text{裸眼}}} = \frac{\ln\left(r_e/r_w\right)}{\ln\left(r_e/r_w\right) + S_f} \quad , \tag{7}$$

$$S_f = \ln\left(\frac{r_e}{r_w}\right) \Big/ \frac{Q_{\text{滑套}}}{Q_{\text{裸眼}}} - \ln\left(\frac{r_e}{r_w}\right) \quad , \tag{8}$$

图 3 为不同滑套开度和周向孔数条件下，定生产压差条件下的滑套完井与裸眼完井的出口流量对比结果。结合公式(8)，在已知供给半径和井眼半径的条件下，可直接计算出数值模拟结果下的表皮系数 S_f，如图 4(b)所示。

图 4(a) 为套管柱近井地带压力等势线分布示意图，根据数值模拟的结果可以观察到，水平井滑套完井管柱流动过程中的压力分布特征，将近井地带的流动划分为6个主要的流动区域：滑套孔眼内线性流动、滑套孔眼引起的汇聚流动、割缝内线性流动、单个割缝引起的径向流动、割缝单元引起的径向流动和远离割缝筛管的径向流动。

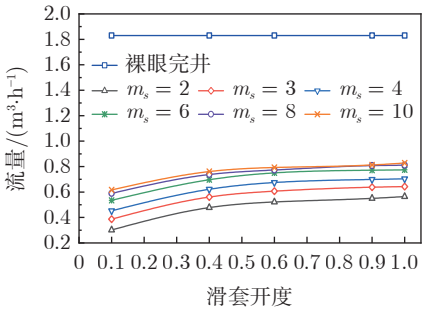


图 3 滑套完井与裸眼完井的出口流量

Fig. 3 Outlet flow rates for sliding-sleeve and open-hole completions.

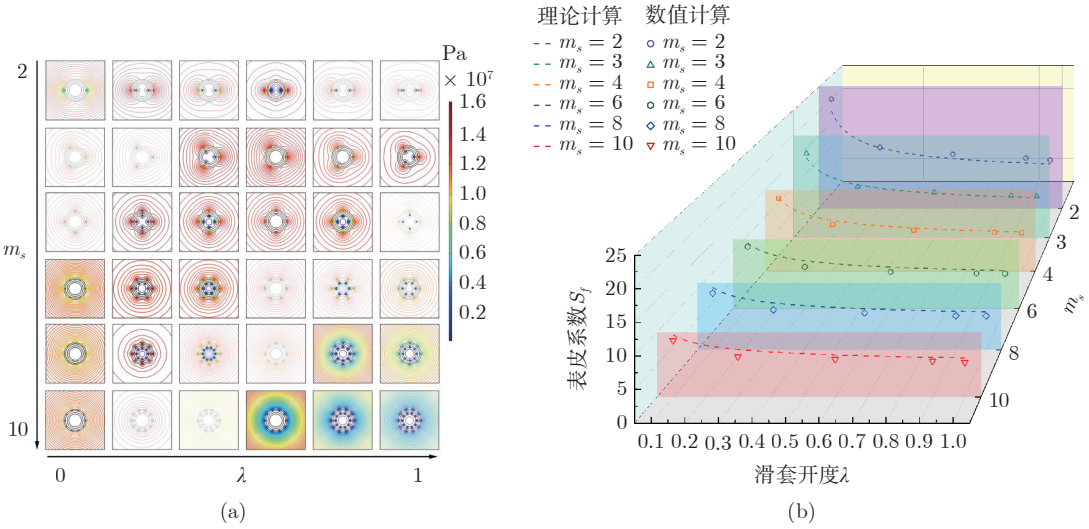


图 4 (a) 套管柱近井地带压力等势线分布示意图 (b)表皮系数计算对比值

Fig. 4 (a) Schematic diagram of pressure equipotential line distribution near the casing string (b) Comparison of skin factor calculation values

根据广义表皮系数的定义，完井表皮是由于实际流道与理想流道偏离引起的压差，非均质储层的表皮系数的积分表达式为[1]：

$$S_f = 2\pi\overline{K}L\left[\int_{\zeta_0}^{\zeta_1}\frac{1}{K(\xi)A(\xi)}\mathrm{d}\xi - \int_{\zeta'_0}^{\zeta'_1}\frac{1}{K(\xi')A(\xi')}\mathrm{d}\xi'\right], \tag{9}$$

式中，$\overline{K}$ 是储层平均渗透率，单位为 10^{-3} μm²；L 是水平段井筒长度，单位为 m；ξ_0 和 ξ_1 为实际流道的起点和终点；ξ'_0 和 ξ'_1 为理想流道的起点和终点；$K(\xi)$ 与 $K(\xi')$ 是实际流动与理想流动状态沿流道不同位置处的渗透率，单位为 10^{-3} μm²；$A(\xi)$ 与 $A(\xi')$ 是实际流道与理想流道的过流断面积，单位为 m²。结合图 4(a) 流动区域划分所确定的积分上限，通过叠加可构建智能滑套完井的表皮系数理论模型，由6个部分构成：。

$$S_f = S_{hl} + S_{hr} + S_{sl} + S_{sr} + S_{su} + S_{sa}, \tag{10}$$

式中 S_{hl} 是滑套孔眼内线性流动引起的表皮；S_{hr} 是滑套孔眼汇聚流动引起的表皮；S_{sl} 是割缝内线性流动引起的表皮；S_{sr} 是单个割缝引起引起的表皮；S_{su} 是割缝单元引起的表皮；S_{sa} 是远离割缝筛管的径向流动引起的表皮。

基于上述的6个图 4(b) 为不同周向开口数 m_s 条件下的滑套完井表皮系数计算值，可观测到理论计算值与数值计算结果吻合程度较高，其平均误差在6%以内，能有效计算水平井产能。

1.2.2　滑套完井管柱表皮理论模型

由公式(9)和(10)可知, 表皮系数的理论模型是由实际流道与理想流道的流动路径积分函数构建, 可将压降与表皮系数的关系, 转换为表皮系数 S_f 与流动积分区域的关系。滑套孔眼内线性流可以描述为:

$$S_{hl}=\frac{2\pi L\overline{K}t_h}{K_hA_s}\quad , \tag{11}$$

式中 L 是滑套完井管柱长度, 单位为 m; $\overline{K}$ 是储层平均渗透率, 单位为 10^{-3} μm^2; t_H 是滑套管厚度, 单位为 m; K_h 是滑套孔眼渗透率, 单位为 10^{-3} μm^2; A_s 为滑套孔眼的开启面积, 单位为 m^2。

滑套孔眼内线性流可以描述为:

$$S_{hr}=\int_{r_o}^{r_c}\frac{1}{\pi r\left[\dfrac{\sqrt{\pi rh_s}-h_c}{r_c-r_o}(r-r_o)+h_c\right]}\quad , \tag{12}$$

式中 r_c 为滑套孔眼汇聚流上边界, 单位为 m; r_0 为滑套孔眼汇聚流下边界, 单位为 m; h_c 为滑套孔眼轴向间距, 单位为 m; h_s 为滑套孔眼径向上到筛管内壁的距离, 单位为 m。

综合滑套孔眼和割缝筛管所引起的滑套表皮, 将得到的理论表皮模型与数值结果进行对比验证。采用了不同开度下, 不同滑套每周孔数 m_s=2, m_s=3, m_s=4, m_s=6, m_s=8 和 m_s=10 的表皮系数模拟结果, 并与理论值进行对比, 其表皮平均误差为6%, 误差范围在±12%以内, 如图5所示。该误差水平在油藏工程中是可接受的[34], 因此本文推导的表皮理论计算模型具备工程应用价值。

2　滑套开度优化的深度强化学习模型

2.1　马尔科夫决策模型

使用深度学习表征值函数和策略函数, 滑套完井管柱与环境交互获取水平井生产动态数据的过程可以简化为一个马尔科夫决策过程 (Markov Decision Process, MDP) 模型, 如图6所示。每个滑套视作一个智能体, 该模型主要由状态 S, 动作 A, 奖励 R 和策略 μ 这 4 个部分组成[35]。状态 S 表示水平井当前的生产动态信息, 不同的状态会对应不同动作策略; 动作 A 表示滑套完井管柱的开度状态; 奖励 R 表示与环境交互过程中对该动作的评价, 引导智能体学习; 策略 μ 表示水平井根据当前状态采取的控制策略。在不同的储层渗透率、压力条件和滑套开度组合下, 模拟水平井产量、含水率等信息, 并将时间序列截取为强化学习状态; 每个动作对应于改变某段滑套开度的离散水平。训练样本由状态–动作–奖励–下一个状态的四元组组成。

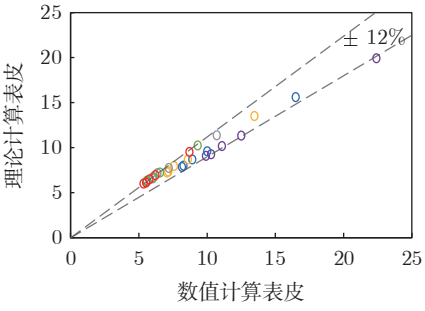


图 5　表皮系数数模值与理论值误差分析

Fig. 5　Error analysis between numerical simulation values and theoretical values of skin factor.

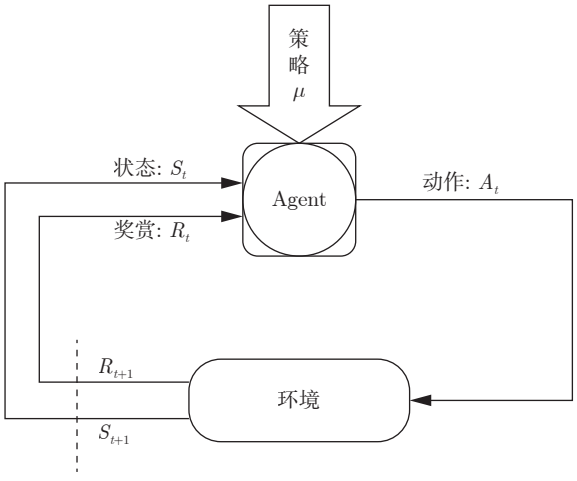


图 6　基于MPD的强化学习模型

Fig. 6　Reinforcement learning model based on MPD.

2.1.1　状态空间

在复杂运行环境下, 为了准确描述水平井生产过程的动态信息, 本文选择水平井的井段产油量和井段含

水率组成状态空间，定义为 s_t：

$$s_t = [q_{oi,t}, f_{wi,t}], q_{oi,t} \in [0, q_l], f_{wi,t} \in [0,1] \quad , \tag{13}$$

$$f_{wi,t} = \frac{q_{wi,t}}{q_{oi,t} + q_{wi,t}} \quad , \tag{14}$$

其中，$q_{oi,t}$、$q_{wi,t}$和 $f_{wi,t}$ 分别为当前时刻水平井每一段的产油量、产水量和含水率；q_l表示定产液量进行生产的出口产液量。状态空间的动态信息 s_t可通过公式(5)、(6)计算产油与产水量，通过公式(14)计算含水率。

2.1.2 动作空间

根据水平井在生产过程中连续的产油量和含水率变化信息，因此本文的动作空间 A 由井段的含水率 f_w 和对应滑套的开度 λ_i 组合：

$$A = [\lambda_i], \lambda = \begin{cases} 0 & f_w > x_1 \\ 0.1 & x_2 < f_w \leqslant x_1 \\ 0.4 & x_3 < f_w \leqslant x_2 \\ 0.6 & x_4 < f_w \leqslant x_3 \\ 0.9 & x_5 < f_w \leqslant x_4 \\ 1 & 0 < f_w \leqslant x_5 \end{cases} \quad , \tag{15}$$

其中：$1 > x_1 > x_2 > x_3 > x_4 > x_5 > 0$

水平井段的含水率 f_w 的范围级别是 [0, 1]，0 表示井段处于无水采油期，1 表示井段被完全水淹；开度根据滑套管柱的实际情况，本研究中所采用的滑套管柱结构共有 6 级，分别是 [0, 0.1, 0.4, 0.6, 0.9, 1]，1 表示滑套完全开启状态，0 表示滑套完全关闭状态。

2.1.3 奖励机制设定

智能体可根据定义的状态和动作，随机生成控制策略，通过不同的奖赏值引导算法学习更好的控制策略，使获得的回报最大。合理的奖惩机制能够提高收敛速度，通常情况下，形式化的奖励会比稀疏奖励更容易促进学习。本文根据水平井的产能模型，以产油量最大 R_{pro}，综合含水率最小 R_w 和动作成本最小 R_c 构建连续型奖励函数，引导滑套完井管柱寻找最优控制策略：

$$R = R_{pro} - R_w - R_c = w_o \frac{q_{oi,t}}{q_{l,\max}} - w_w f_{wi,t} - w_c C_t \quad , \tag{16}$$

$$C_t = \boldsymbol{\eta} |a_t - a_{t-1}| \quad , \tag{17}$$

式中 $q_{l,max}$ 为归一化因子；w_o 是产油权重，取值 1；w_w 是含水率权重，取值 0.3；w_c 是动作成本权重，用于平衡指标。C_t 是为了考虑频繁调节滑套开度的机械磨损和操作成本，在奖励函数中加入的对动作变化幅度的惩罚项，a_t 为当前滑套开度动作；$a_{t\text{-}1}$ 为上一步动作；η 惩罚强度，取值 0.05。

产油量奖赏机制 R_{pro} 为油井产能的重要指标，其价值体现在多个关键维度，贯穿油田开发的经济效益、技术决策和战略管理全过程。根据公式(18)实时计算累计产油量。

$$Q_{o_all} = \sum_{i=1}^{n} \sum_{t=1}^{T} q_{oi,t} \quad , \tag{18}$$

2.1.4 奖励机制设定

滑套完井管柱在当前状态下选择一个动作执行称为策略 μ，智能体选择当前状态下状态-动作函数 Q 值最大的动作，状态-动作函数 Q 定义为：

$$Q(s_t, \boldsymbol{\mu}(s_t)) = E[R(s_t, \boldsymbol{\mu}(s_t)) + \boldsymbol{\gamma} Q(s_{t+1}, \boldsymbol{\mu}(s_{t+1}))] \quad , \tag{19}$$

其中，γ 表示折扣因子，γ 越大表示更关注未来的回报。

2.2 PER-MADDPG 算法

2.2.1 MADDPG 算法

本研究针对水平井多级滑套协同优化问题，将每个滑套视为一个独立的智能体，采用多智能体深度确定

性策略梯度算法构建优化模型。MADDPG算法采用“集中式训练, 分布式执行”的架构[36], 适用于水平井多段智能滑套完井的信息独立决策, 也能满足全局累产油最大的协同优化。算法核心由多个策略网络、多个Actor-Critic网络、一个共享的经验回放池、代表油藏动态的产能数值模拟器(环境)以及引导协同的组合状态与动作奖励函数构成, 训练过程如图7所示。在训练过程中, 环境在每个时间步 t 与所有滑套智能体交互, 每一时刻的数据由 $(s_t, a_1, ..., a_N, r_1, \cdots, r_N, s_{t+1})$ 组成, 其中 $s_t=(s_1, ..., s_N)$ 表示当前时刻所有滑套的联合观测状态向量, $a_t=(a_1, \cdots, a_N)$ 为各智能体在该时刻采取的动作组合, $r_t=(r_1, \cdots, r_N)$ 为对应的奖励向量, s_{t+1} 为下一时刻的联合状态。

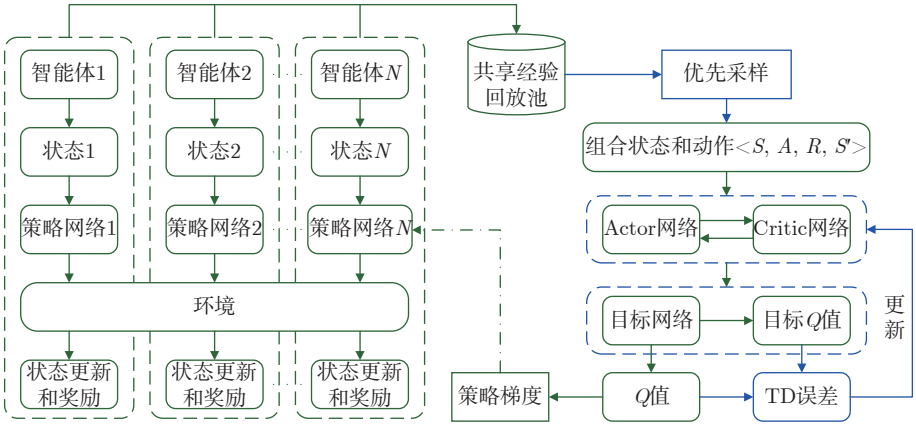


图 7　PER-MADDPG算法框架

Fig. 7　Framework of the PER-MADDPG algorithm

Critic 网络用于评价滑套完井当前控制策略的好坏, 其网络参数为 θ^Q, 输出为一个全局价值估计 $Q(s, a|\theta^Q)=Q(s, a)$, 用于评价在全局状态 s 下采取联合动作 a 对智能体 i 长期目标的贡献; Actor 网络采用基于策略梯度更新的方式, 网路参数为 θ^μ, 用于独立输出每个智能体的滑套完井控制策略 a_i。采用式(20) ~ (22)计算神经网络参数新的权重。

$$\boldsymbol{\theta}_{t+1}^{Q}=\boldsymbol{\theta}^{Q}+\boldsymbol{\alpha}_{Q}\left[y'-y_t\right]\nabla Q\left(s, a'\boldsymbol{\theta}_t^{Q}\right) \quad , \tag{20}$$

$$y_t=Q\left(s_t, \boldsymbol{\mu}_t(s_t\,|\boldsymbol{\theta}^{\mu_t})|\,\boldsymbol{\theta}^{Q}\right) \quad , \tag{21}$$

$$y'_t=r_t+\boldsymbol{\gamma}Q_{t+1}\left(s_{t+1}, \boldsymbol{\mu}_t(s_{t+1}\,|\boldsymbol{\theta}^{\mu_t})|\,\boldsymbol{\theta}^{Q}\right) \quad , \tag{22}$$

其中, y'_t 为目标值; α_Q 为学习率; $\nabla Q(s, a'\theta_t^Q)$ 为Critic 神经网络根据 Q 值计算出的更新梯度, 输出给 Actor 网络作为更新动作策略的依据, 若梯度为正, 表示最优策略向此控制策略靠近, 梯度越大, 靠近速度更快。其策略梯度的计算公式 $J(\mu)$:

$$\nabla_{\boldsymbol{\theta}^{\mu}}J\approx E\left[Q\left(s, a|\boldsymbol{\theta}^{Q}\right)|_{a=\boldsymbol{\mu}(s_i)}\cdot\nabla_{\boldsymbol{\theta}^{\mu}}\boldsymbol{\mu}\left(s|\boldsymbol{\theta}^{\mu}\right)\right] \quad , \tag{23}$$

2.2.2　优先经验回放机制引入

MADDPG中每个智能体的经验存储为: $(s, a_1, \cdots, a_N, r_1, \cdots r_N, s')$, 其中 s 是所有智能体的联合状态, a_i 是智能体 i 的动作。为了提高MADDPG 算法的计算效率及收敛性, 本研究根据经验样本的学习价值赋予不同的采样优先级, 从而提升多智能体协作学习的效率和稳定性。选择了时间差分(temporal difference, TD)误差 δ, 其表达式为[37]:

$$\boldsymbol{\delta}=\left(y-Q^{\boldsymbol{\pi}}\left(s, a_1, a_2, \cdots, a_N\right)\right) \quad , \tag{24}$$

δ 越大, 在该状态处学习效率越高, 设样本 i 处的 TD 偏差为 δ_i, 则该样本处的采样概率 p_i 为:

$$p_i=\frac{p_i^{\boldsymbol{\alpha}}}{\sum\limits_{k}p_k^{\boldsymbol{\alpha}}} \quad , \tag{25}$$

式中 α 为优先级的放大指数, α 越大, 表明 p_i 的抽取经验的权重越大, 本文取 α=0.6, 可兼顾学习效率和样本多样性[38]。最终, 验缓存池的元素记录了所有智能体的经验数据, 同时 Critic 网络通过优化损失函数来进行更

新，网络的输入包括其他智能体的观测值和采取的动作，形成PER-MADDPG算法，流程图如图7所示，其蓝色流程部分即为改进的TD误差优先经验回放机制。

3 实例应用

南海东部大多数油田为海相沉积大型底水油藏，采用水平井高效开发，底水锥进导致区域含水上升快的问题。截至到2022年底，南海东部累计实施控水完井226口（180口井在产），为实现稳油控水目的，番禺油田引进了滑套完井技术，在南海东部地区的某井进行了应用试验。该油藏表现为强底水，非均质性强的特性，其油藏物性参数与水平井基础参数如下表2所示。为了有效控制底水脊进造成的水平井筒快速水淹现象，采用了引入智能滑套控制系统的水平井控水完井技术，其开发模型如图8所示。

表 2 油藏基本参数

Table 2 Petrophysical property and horizontal well parameters

参数	值	单位	参数	值	单位
原油黏度	47.85	mPa·s	油藏长度	920	m
原油密度	912	kg/m^3	油藏高度	6	m
地层油体积系数	1.2	m^3/m^3	油藏宽度	800	m
地层水黏度	0.28	mPa·s	油藏压力	19.78	MPa
地层水密度	998.2	kg/m^3	井筒半径	0.112 25	m
地层水体积系数	1.035	m^3/m^3	井筒长度	920	m

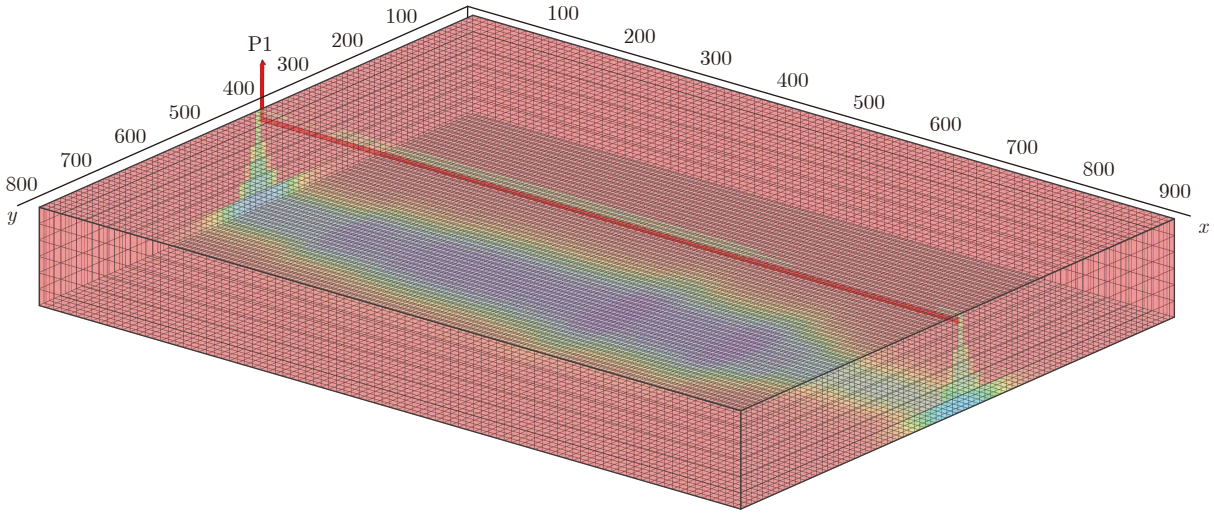


图 8 水平井油藏开发模型

Fig. 8 Horizontal well reservoir development model

水平井眼中共下入 92 根智能滑套控水管柱，每根控水管柱长 10 m，沿水平段渗透率通过测井解释数据获得，经处理后的渗透率分布如图9 所示。根据该井的生产情况，设置智能体数量N=92，每30天为一时间步，以定产液量950m^3/d的制度进行生产10年，总时间步长为T=122，其他的PER-MADDPG的超参数如表3所示。

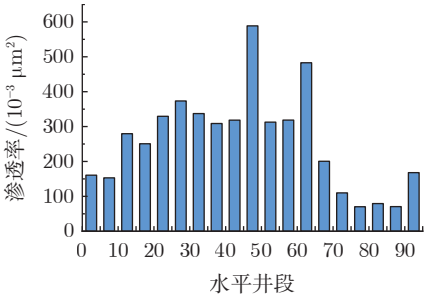


图 9 沿水平段渗透率分布

Fig. 9 Permeability distribution along the horizontal section

3.1 流入动态结果分析

图10 和图11为采用PER-MADDPG优化前后的

水平井段入流量率变化对比图。通过渗透率沿水平段的分布数据可以观测到该油藏的非均质性特征, 高渗层集中在47 ~ 51、60 ~ 68水平段, 低渗层主要位于1 ~ 10、73 ~ 91水平段。由于储层初期含水差异不大, 而渗透性差异显著, 从图10(a)—(d)可以观察到, 采用未优化的滑套完井系统开发该储层时, 水平井流入动态特征主要取决于渗透率分布。流体容易在470 ~ 510 m、640 ~ 680 m区域发生底水脊进, 这会导致局部产层的快速水淹。而在730 ~ 910 m处, 水平井段的入流量会受到抑制, 使得油水界面均匀推进。在开发过程中, 注入流体倾向于沿高渗层“指状”突进, 高渗通道的流动阻力持续减小, 而低渗区域则难以被有效动用, 导致产液剖面恶化、含水率急剧上升, 从而显著降低驱替效率与最终采收率。从图11(a)—(d)可以观察到, 在采用了PER-MADDPG优化了滑套系统的开度策略算法后, 水平井段的产液剖面有了明显的改善。在生产1年后, 高渗层段的产液量峰值从76 m^3/10m降低到了57 m^3/10 m, 低渗段的产液量也有了明显的提升。在生产2年后, 高渗层的优势流道形成后, 虽因其高含水而抑制了该段油相产量, 但在跟部和趾部的低渗段的原油被有效驱动, 提升了波及效率与开发效益。

表 3　PER-MADDPG的超参数

Table 3　Hyperparameters of PER-MADDPG parameters

超参数	值	超参数	值
网络层数	2	经验回放池容量	1×10^5
每层节点数	128	批量大小	1 024
Actor 学习率	1×10^{-4}	优先经验回放指数	0.6
Critic学习率	5×10^{-4}	优化器	Adam
折扣因子	0.95	训练轮次	200

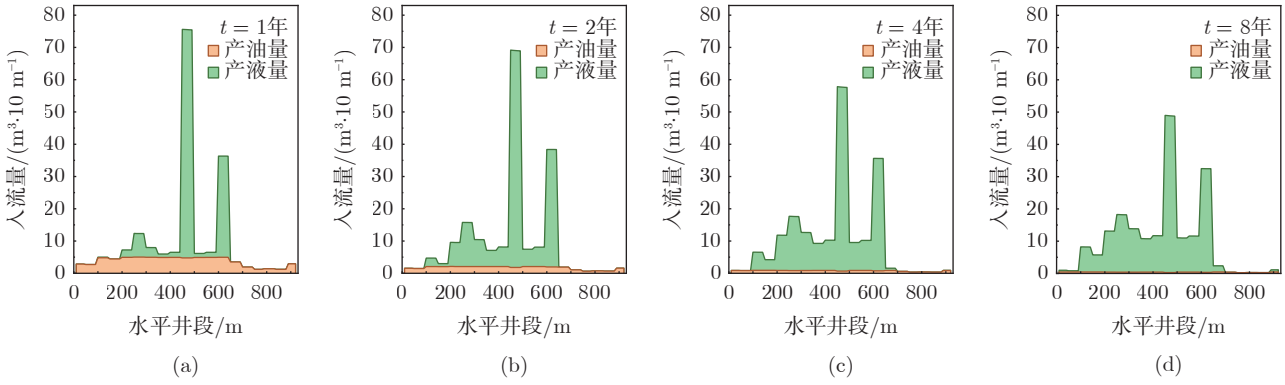


图 10　采用PER-MADDPG优化前的水平井段入流量(a)$t = 1$年; (b)$t = 2$年; (c)$t = 3$年; (d)$t = 4$年.

Fig. 10　Inflow along the horizontal well section before using PER-MADDPG optimization (a) $t = 1$year; (b) $t = 2$ years; (c) $t = 3$ years; (d) $t = 4$ years.

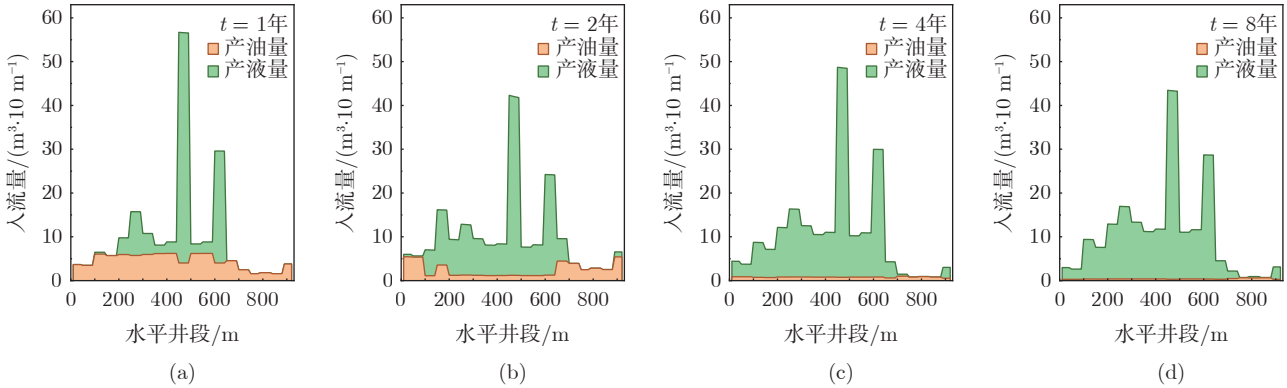


图 11　采用PER-MADDPG优化后的水平井段入流量(a)$t = 1$年; (b) $t = 2$年; (c)$t = 3$年; (d) $t = 4$年.

Fig. 11　Inflow along the horizontal well section after using PER-MADDPG optimization (a)$t = 1$year; (b) $t = 2$ years; (c) $t = 3$ years; (d) $t = 4$ years.

为了从完整井筒的产能上分析PER-MADDPG算法的优化效果, 图12 对比了采用PER-MADDPG优化前后的日产油与综合含水率变化。在生产250天后, 采用 PER-MADDPG 方案的水平井日产油量达到一定程度

的稳油生产效果，其降幅显著小于未优化的滑套控制策略。另一方面，采用了PER-MADDPG优化后的滑套管柱完井，综合含水上升在初期得到了一定控制，生产2年后综合含水从87.4%下降到81.0%，表明该方法具备更好的控水与稳产能力。

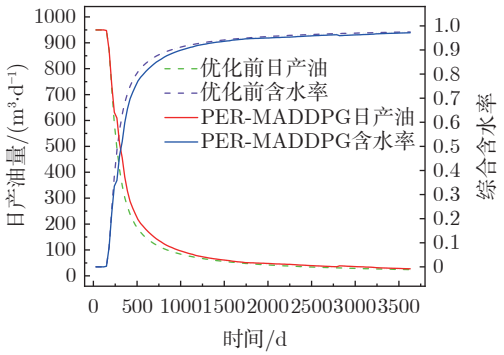


图 12 采用PER-MADDPG优化前后的日产油与综合含水率变化

Fig. 12 Changes in daily oil production and comprehensive water cut before and after PER-MADDPG optimization

3.2 滑套开度策略结果分析

图13是未优化的水平井段含油饱和度变化及滑套开度控制策略。对于未优化的滑套完井系统，控制策略是根据局部产液含水情况进行生产预警并形成响应。当局部含水率＞0.999，认为发生剧烈水淹；当局部含水率＞0.8，认为发生严重水淹；当局部含水率＞0.6，认为发生明显水淹；当局部含水率＞0.4，认为发生水淹；当局部含水率＞0.2，认为发生轻微水淹。根据不同的水淹预警程度，将采取对应的滑套开度调控策略。但由于水淹要考虑到全井段综合生产动态的变化，每一井段段当前时间步的相对渗透率、含水率及水平层段的非均匀产液剖面的互相干扰，都会对下一时刻的流入动态计算产生影响。因此，采用固定的生产预警区间划分，难以实现滑套完井系统优化效益的最大化。

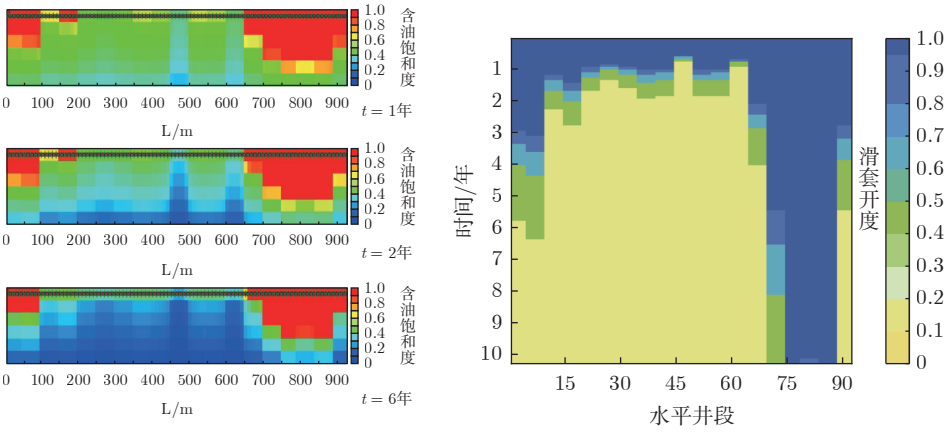


图 13 (a) 未优化的水平井段含油饱和度变化 (b) 未优化的水平井段滑套开度控制策略

Fig. 13 (a) Oil saturation change in the unoptimized horizontal well section (b) Control strategy of sliding sleeve opening in the unoptimized horizontal well section

图14是采用了PER-MADDPG优化后的水平井段含油饱和度变化及滑套开度控制策略。将井筒-滑套-储层耦合流动的产能模型作为综合环境，开展水平井生产优化研究。可以再看出，在生产2年后，水平井段的含油饱和度分布更加均匀，在470～510 m、640～680 m区域的底水脊进现象明显减弱。在生产接近6年时，高渗段的滑套开度策略首次降到了0，这表明优化后的滑套完井系统能够根据考虑当前时间步的相对渗透率、含水率及水平层段的非均匀产液剖面的互相干扰，而提前做出响应的预警并且有效地训练了每一个智能完井段的滑套开度策略系统。

3.3 算法对比

将基于PER-MADDPG算法的水平井智能滑套完井优化控制模型的训练奖励值变化与其他强化学习模型的奖励值变化进行了比较。这些比较如图15所示。横轴表示训练集数总数，实验中共有 200 轮次。纵轴显示轮次的平均奖励值。从图中可以明显看出，在这DDPG 和 MADDPG 算法都表现出相对较低的奖励值和较差的稳定性。虽然MADDPG算法更稳定，但其算法能达到最佳性能不如PER-MADDPG。

图16呈现了不同优化算法的损失，随着训练的进行PER-MADDPG算法逐渐收敛到接近零，而DDPG算

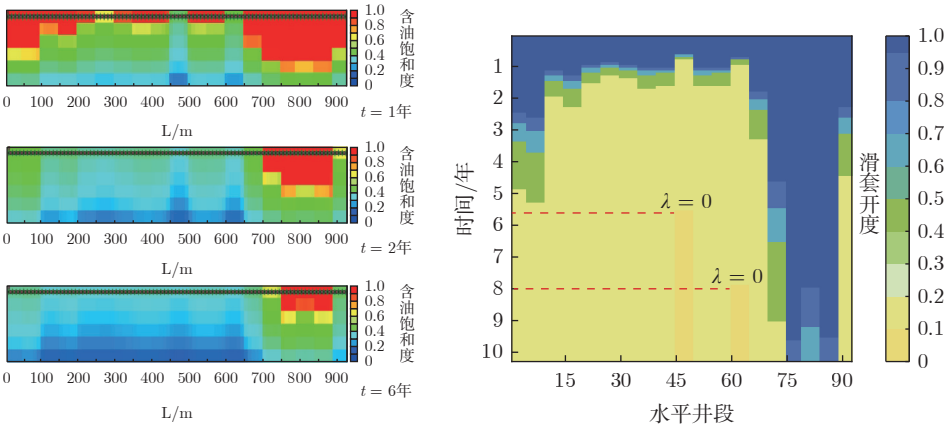


图 14　(a) 优化后的水平井段含油饱和度变化 (b) 优化后的水平井段滑套开度控制策略

Fig. 14　(a) Oil saturation change in the optimized horizontal well section (b) Control strategy of sliding sleeve opening in the optimized horizontal well section

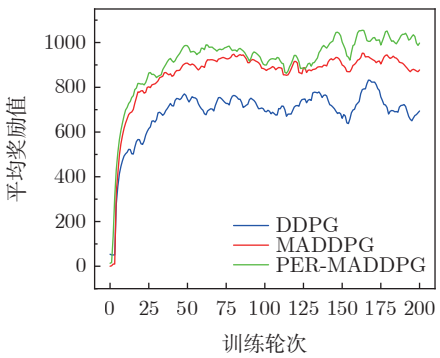


图 15　不同优化算法的平均奖励值

Fig. 15　Average reward values of different optimization algorithms

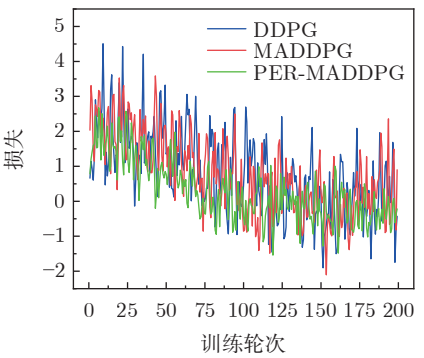


图 16　不同优化算法的损失值

Fig. 16　Loss values of different optimization algorithms

法的振荡显著, 其次是MADDPG算法。这说明对于多智能体的优化, 采用DDPG模型的效果是不理想的, MADDPG算法能得到一定的改善, 但引了优先经验回放机制的PER-MADDPG能充分利用有效数据, 更快收敛, 使得奖励值更高。

图 17是不同优化算法条件下的水平井智能滑套完井累计产油量对比图。其优化效果从大到小依次为PER-MADDPG、MADDPG、DDPG和未优化的完井方案。总体而言, 采用了PER-MADDPG优化的水平井滑套完井的累计产油增加了10.7%; 累计产水减少了1.6%。

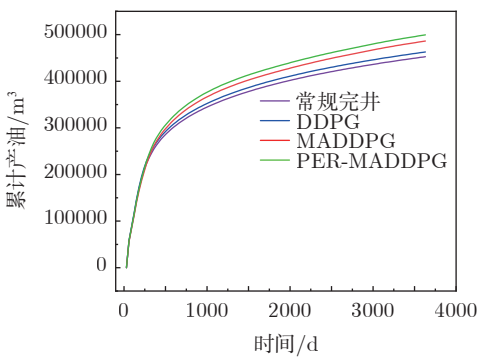


图 17　不同优化算法条件下的累计产油量

Fig. 17　Cumulative oil production under different optimization algorithm conditions

4　结论

本文针对水平井智能滑套完井系统的开度优化问题, 提出了一种基于优先经验回放机制的多智能体强化学习算法(PER-MADDPG)。通过构建滑套-储层耦合流动模型, 并结合改进的智能决策框架, 实现了对生产过程中多段智能滑套开度的协同优化。本研究主要得到以下结论:

(1)本文建立的耦合流动模型能够有效反映水平井分段生产动态, 为智能优化提供了可靠的模拟环境。

该模型经过对比验证，可用于支持实时生产分析与调控决策。

（2）PER-MADDPG算法通过重点学习关键生产经验，显著提高了训练效率与策略稳定性。优化后各井段产液剖面趋于均衡，高渗段液量得到抑制，低渗段原油动用程度提高，整体开发效果得到改善。

（3）与现有优化方法相比，PER-MADDPG在收敛速度与最终优化效果上均表现出优势，在提高原油产量的同时有效控制了含水率上升，验证了该方法在智能完井实时调控中的应用潜力。

该研究为多变量、强耦合的油井生产优化问题提供了一种数据驱动与强化学习相结合的解决思路，对推动智能油田调控技术的发展具有参考意义。

参 考 文 献

[1] 汪志明. 复杂结构井完井优化理论及应用 [M]. 北京: 石油工业出版社, 2010: 53-79.

[2] 谭吕, 张宁, 秦世利, 等. 考虑颗粒充填的水平井控水完井产量预测方法 [J]. 石油钻采工艺, 2024, 46(1): 78-88.

[3] 贾品, 程林松, 黄世军, 等. 水平井体积压裂缝网表征及流动耦合模型 [J]. 计算物理, 2015, 32(6): 685-692.

[4] 龚宁, 李进, 陈娜, 等. 渤海油田水平井出水特征及控水效果评价方法 [J]. 特种油气藏, 2019, 26(5): 147-152.

[5] LI Binwang, WANG Zhiming, ZENG Quanshu. A skin factor model of sliding sleeve and its production optimization[C]//the International Petroleum Technology Conference. Dhahran, Saudi Arabia: IPTC, 2024: IPTC-23705-MS.

[6] 黎伟, 夏杨, 陈曦. RFID智能滑套设计与试验研究 [J]. 石油钻探技术, 2019, 47(6): 83-88.

[7] 曾泉树, 郝希宁, 隋天阳, 等. 水平井滑套完井管柱井筒压降预测方法与应用 [J]. 特种油气藏, 2024, 31(2): 159-165.

[8] 刘景超, 王金龙, 武宇琛. 智能完井井下智能滑套位移监测系统研制 [J]. 石油机械, 2023, 51(2): 1-8.

[9] 孙昕迪, 白宝君. 国内外水平井控水技术研究现状 [J]. 石油勘探与开发, 2017, 44(6): 967-973.

[10] ZHANG Ruxin, CHEN Hongquan. Robust waterflood optimization under geological uncertainties using streamline-based well pair efficiencies and assimilated models[J]. Geoenergy Science and Engineering, 2023, 231, Part A: 212309.

[11] WANG Lian, YAO Yuedong, LUO Xiaodong, et al. A critical review on intelligent optimization algorithms and surrogate models for conventional and unconventional reservoir production optimization[J]. Fuel, 2023, 350: 128826.

[12] ZHANG Kai, WANG Zhongzheng, CHEN Guodong, et al. Training effective deep reinforcement learning agents for real-time life-cycle production optimization[J]. Journal of Petroleum Science and Engineering, 2022, 208, Part E: 109766.

[13] 徐光辉, 李俊键, 肖康, 等. 基于改进间歇泉算法的高倾角油藏气水双向驱自动优化 [J/OL]. 计算物理, 2025: 1-14(2025-08-20) [2026-01-08]. https://link.cnki.net/urlid/11.2011.o4.20250819.1648.002.

[14] NASIR Y, HE Jincong, HU Chaoshu, et al. Deep reinforcement learning for constrained field development optimization in subsurface two-phase flow[J]. Frontiers in Applied Mathematics and Statistics, 2021, 7: 689934.

[15] ZHAO Mengjie, ZHANG Kai, CHEN Guodong, et al. A surrogate-assisted multi-objective evolutionary algorithm with dimension-reduction for production optimization[J]. Journal of Petroleum Science and Engineering, 2020, 192: 107192.

[16] LIU Chen, GONG Bin, WU Haoqiang, et al. Intelligent coalbed methane drainage optimization: A deep reinforcement learning-driven life-cycle strategy[J]. Energy and AI, 2025, 22: 100598.

[17] HOURFAR F, BIDGOLY H J, MOSHIRI B, et al. A reinforcement learning approach for waterflooding optimization in petroleum reservoirs[J]. Engineering Applications of Artificial Intelligence, 2019, 77: 98-116.

[18] KIM J, YANG H, CHOE J. Robust optimization of the locations and types of multiple wells using CNN based proxy models[J]. Journal of Petroleum Science and Engineering, 2020, 193: 107424.

[19] ZHANG Kai, SUN Zifeng, ZHANG Liming, et al. A maximum entropy deep reinforcement learning method for sequential well placement optimization using multi-discrete action spaces[J]. Geoenergy Science and Engineering, 2024, 240: 213004.

[20] YAN Bingyang, ZHONG Zhi. Deep reinforcement learning for optimal hydraulic fracturing design in real-time production optimization[J]. Geoenergy Science and Engineering, 2025, 250: 213815.

[21] MA Qinghua, LI Dong, ZHANG Xuemei. Numerical simulation of critical depth of methane adsorption in middle-rank coal[C]//Proceedings of the International Field Exploration and Development Conference 2020. Singapore: Springer, 2020: 102523.

[22] NASIR Y, DURLOFSKY L J. Multi-asset closed-loop reservoir management using deep reinforcement learning[J].

Computational Geosciences, 2024, 28(1): 23-42.

[23] GUEVARA J L, PATEL R, TRIVEDI J. Optimization of steam injection in SAGD using reinforcement learning[J]. Journal of Petroleum Science and Engineering, 2021, 206: 108735.

[24] MA Hongze, Yu Gaoming, SHE Yuehui. Water flooding optimization under geological uncertainties by using deep reinforcement learning algorithms[C]//the SPE Annual Technical Conference and Exhibition. Calgary, Alberta, Canada: SPE, 2019: SPE-196190-MS.

[25] LI Rongtao, LIAO Xinwei, WANG Xiaoyan. A multi-agent deep reinforcement learning method for co2 flooding rates optimization[J]. Energy Exploration & Exploitation, 2022, 41: 224-245.

[26] ABDALLA R, AGBAN N, LÜDDEKE C, et al. Multi agent physics informed reinforcement learning for waterflooding optimization[J]. Franklin Open, 2025, 10: 100229.

[27] 董鹏, 廖新维. 基于代理模型和深度强化学习的试井自动解释方法 [J]. 计算物理, 2023, 40(1): 67-80.

[28] 李大建, 吴春生, 崔子岳, 等. 底水油藏水平井套外光纤智能完井技术试验 [J]. 石油机械, 2025, 53(7): 129-135.

[29] 黄朝琴, 姚军, 王月英, 等. 基于离散裂缝模型的裂缝性油藏注水开发数值模拟 [J]. 计算物理, 2011, 28(1): 41-49.

[30] 岳大力, 吴胜和, 程会明, 等. 基于三维储层构型模型的油藏数值模拟及剩余油分布模式 [J]. 中国石油大学学报(自然科学版), 2008, 32(2): 21-27.

[31] 范天一, 宋新民, 吴淑红, 等. 低渗透油藏水驱动态裂缝数学模型及数值模拟 [J]. 石油勘探与开发, 2015, 42(4): 496-501.

[32] FURUI K, ZHU D, HILL A. A rigorous formation damage skin factor and reservoir inflow model for a horizontal well[J]. SPE Production & Facilities, 2003, 18(3): 151-157.

[33] FURUI K, ZHU D, HILL A D. A comprehensive skin-factor model of horizontal-well completion performance[J]. SPE Production & Facilities, 2005, 20(3): 207-220.

[34] 黄世军, 程林松, 赵凤兰, 等. 考虑生产段表皮因子变化的水平井产能模型 [J]. 钻采工艺, 2005, 28(5): 31-34.

[35] 黄子蓉, 甯彦淞, 王莉. 基于优先经验回放的多智能体协同算法 [J]. 太原理工大学学报, 2021, 52(5): 747-753.

[36] 丁世飞, 杜威, 郭丽丽, 等. 基于双评论家的多智能体深度确定性策略梯度方法 [J]. 计算机研究与发展, 2023, 60(10): 2394-2404.

[37] 高昂, 董志明, 李亮, 等. MADDPG算法并行优先经验回放机制 [J]. 系统工程与电子技术, 2021, 43(2): 420-433.

[38] ZHANG Hongjie, QU Cheng, ZHANG Jindou, et al. Self-adaptive priority correction for prioritized experience replay[J]. Applied Sciences, 2020, 10(19): 6925.

Optimization of Intelligent Sliding Sleeve Opening in Horizontal Well Completion Using an Improved MADDPG Algorithm

LI Binwang [1], WANG Zhiming [1]

(1. *College of Petroleum Engineering, China University of Petroleum (Beijing), Beijing* 102249, *China*)

Abstract: Optimizing the opening settings of an intelligent sliding sleeve completion system in horizontal wells is a challenging problem due to its multivariable, strongly coupled, and nonlinear nature. In this study, a coupled flow model for the sliding sleeve-reservoir system in a horizontal well is developed and validated against numerical simulation, with relative errors within 12%. Based on this model, a reinforcement learning framework guided by Markov decision theory is adopted. By incorporating prioritized experience replay (PER) into the multi-agent deep deterministic policy gradient (MADDPG) framework, a PER-MADDPG algorithm is proposed to optimize multistage sliding sleeve completion in horizontal wells. The results indicate that, compared with DDPG and conventional MADDPG, PER-MADDPG achieves higher rewards with lower training loss and improved convergence. The optimized strategy increases cumulative oil production by 10.7% and reduces the water cut by 6.4% after two years of production. By selectively prioritizing and replaying informative experiences, PER-MADDPG significantly enhances learning efficiency and sample utilization, providing theoretical support for real-time multi-agent control in horizontal well production.

Key words: Sliding Sleeve Completion; Reservoir Numerical Simulation; Deep Reinforcement Learning; Multi-Agent Deep Deterministic Policy Gradient

Received date: 2025-12-02; **Revised date:** 2026-01-08